



UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE - UFRN
CENTRO DE ENSINO SUPERIOR DO SERIDÓ - CERES
DEPARTAMENTO DE COMPUTAÇÃO E TECNOLOGIA DCT



LUCAS DA COSTA SANTOS

Matrícula: 20250038952

Relatório Técnico: Análise Exploratória e Preparação de Dados para Modelos de Aprendizado de Máquina

Link do Dataset: <https://www.kaggle.com/datasets/harpartapsin/gh13/movie-genre-recommender-dataset/data>

Repositório GitHub:

https://github.com/lucascsantos07/analise_preparacao_dados

LUCAS DA COSTA SANTOS

Relatório Técnico: Análise Exploratória e Preparação de Dados para Modelos de Aprendizado de Máquina

Relatório de atividades apresentado como requisito para obtenção de nota na disciplina **Inteligência Artificial**, ofertada pela UFRN no período letivo 2026.2.

Professor: Prof. Dr. Thommas K. S. Flores

Universidade Federal do Rio Grande do Norte - UFRN
Centro de Ensino Superior do Seridó - CERES
Departamento de Computação e Tecnologia - DCT

Caicó - RN
2026

Índice

1	Introdução	4
2	Análise Exploratória dos Dados	4
2.1	Inspeção inicial	4
2.2	Estatísticas Descritivas	4
2.3	Valores Ausentes	5
2.4	Detecção de <i>Outliers</i>	7
2.5	Correlação entre as variáveis numéricas	10
2.6	Distribuição das variáveis numéricas	11
2.7	Distribuição das variáveis categóricas	12
3	Limpeza e Pré-processamento	15
3.1	Tratamento de Valores Ausentes	15
3.2	Tratamento de <i>Outliers</i>	15
3.3	Codificação das Variáveis Categóricas	15
3.4	Padronização das Variáveis Numéricas	15
4	Percepções para Classificação	16
4.1	Seleção da Variável-Alvo	16
4.2	Features Recomendadas	16
4.3	Desafios	16
4.4	Algoritmos Sugeridos	16
5	Percepções para Regressão	16
5.1	Seleção da Variável-Alvo	16
5.2	Features Recomendadas	17
5.3	Desafios	17
5.4	Algoritmos Sugeridos	17
6	Considerações Finais	18

Lista de Figuras

1	Distribuição dos valores ausentes nas variáveis categóricas.	6
2	Boxplot da variável mood_score.	7
3	Boxplot da variável social_media_hours_per_day.	8
4	Matriz de correlação de Spearman das variáveis numéricas.	11
5	Assimetria das variáveis numéricas.	12
6	Distribuição das faixas etárias.	13
7	Distribuição do gênero de jogo favorito.	14
8	Distribuição do gênero de filme recomendado.	14

1 Introdução

A Engenharia e Preparação de Dados é uma etapa importante no desenvolvimento de soluções de Aprendizado de Máquina, pois permite identificar problemas, características e relações presentes nos dados antes da construção dos modelos.

Este trabalho utiliza o conjunto de dados *Movie Genre Recommender Dataset*, composto por 6.000 registros e 35 atributos, contendo informações demográficas, comportamentais, psicológicas e preferências relacionadas ao consumo de mídia.

O objetivo deste trabalho é realizar uma análise exploratória dos dados, identificando suas principais características, valores ausentes, possíveis *outliers* e relações entre as variáveis. A partir dos resultados obtidos, são realizadas a limpeza e o pré-processamento dos dados, buscando prepará-los para a análise de dois problemas de aprendizado supervisionado: regressão e classificação. Por fim, são analisadas as características mais relevantes e propostas abordagens adequadas para cada um dos problemas.

2 Análise Exploratória dos Dados

2.1 Inspeção inicial

Inicialmente, o conjunto de dados foi carregado utilizando a biblioteca *Pandas*, permitindo a realização das etapas de inspeção e análise exploratória. Foram verificadas as primeiras e últimas observações, as dimensões do conjunto de dados e os tipos de dados presentes em cada atributo.

O conjunto de dados possui 6.000 registros e 35 atributos. Foram identificadas 10 variáveis numéricas e 25 variáveis categóricas ou textuais. Entre as variáveis numéricas estão medidas relacionadas às características dos perfis, como humor, estresse, tolerância ao medo e ao risco, preferência por humor, abertura a experiências, interesse em romance, tempo de uso de redes sociais e quantidade de assinaturas de serviços de streaming.

O atributo `person_id`, apesar de possuir representação numérica, foi considerado apenas como identificador dos registros. Por esse motivo, não foi utilizado como característica nas análises estatísticas ou na futura modelagem, evitando que seu valor numérico fosse interpretado como uma informação relevante sobre o perfil dos indivíduos.

2.2 Estatísticas Descritivas

A análise das estatísticas descritivas foi realizada sobre as variáveis numéricas do conjunto de dados, considerando medidas de tendência central, dispersão e posição. As Tabelas 1 e 2 apresentam os resultados obtidos.

Tabela 1: Estatísticas descritivas das variáveis numéricas - parte 1

Variável	Qtd.	Média	Desvio	Mín.	Q1	Mediana	Q3	Máx.
mood_score	6000	6,20	1,93	1,00	4,90	6,20	7,50	10,00
stress_level	6000	5,01	2,10	1,00	3,60	5,00	6,50	10,00
fear_tolerance	6000	5,03	2,35	1,00	3,30	5,00	6,70	10,00
risk_tolerance	6000	5,03	2,18	1,00	3,50	5,00	6,60	10,00
humor_preference	6000	5,98	2,11	1,00	4,50	6,00	7,50	10,00

Tabela 2: Estatísticas descritivas das variáveis numéricas - parte 2

Variável	Qtd.	Média	Desvio	Mín.	Q1	Mediana	Q3	Máx.
openness_score	6000	5,56	2,13	1,00	4,10	5,60	7,10	10,00
romance_interest	6000	5,06	2,23	1,00	3,40	5,00	6,60	10,00
social_media_hours_per_day	6000	2,59	1,84	0,00	1,20	2,20	3,50	12,00
streaming_subscription_count	6000	2,35	1,31	0,00	1,00	2,00	3,00	5,00

A Tabela 1 e a Tabela 2 apresentam as principais estatísticas descritivas das variáveis numéricas. Todas as variáveis analisadas possuem 6.000 observações, não sendo identificados valores ausentes entre os atributos numéricos.

Observa-se que as variáveis stress_level, fear_tolerance, risk_tolerance, openness_score e romance_interest apresentam médias próximas de 5. Já mood_score apresenta média de 6,20, enquanto humor_preference apresenta média de 5,98. De modo geral, as medianas apresentam valores próximos às respectivas médias, não sendo observadas diferenças acentuadas entre essas medidas de tendência central.

Em relação à dispersão, os desvios padrão das variáveis numéricas relacionadas às características dos perfis variam aproximadamente entre 1,93 e 2,35. Já social_media_hours_per_day apresenta média de 2,59 horas por dia, com valores entre 0 e 12 horas, enquanto streaming_subscription_count apresenta média de 2,35 assinaturas, variando entre 0 e 5.

As medidas de quartis também serão utilizadas nas etapas posteriores para a análise de possíveis valores extremos por meio do Intervalo Interquartil (IQR).

2.3 Valores Ausentes

A análise de valores ausentes identificou ocorrências em apenas duas variáveis categóricas: favorite_game_genre e favorite_music_genre. A primeira apresenta 360 valores ausentes, correspondendo a 6,00% das 6.000 observações, enquanto a segunda apresenta 356 valores ausentes, correspondendo a 5,93%. As demais variáveis não apresentam valores ausentes.

Para complementar a análise quantitativa, foi utilizado um mapa de calor (*heatmap*), apresentado na Figura 1. A visualização permite identificar a ocorrência dos valores ausentes ao longo das observações, sem evidenciar concentração aparente em uma região específica do conjunto de dados.




Figura 1: Distribuição dos valores ausentes nas variáveis categóricas.

Embora a proporção de valores ausentes seja inferior a 6% em ambas as variáveis, sua presença deve ser considerada na etapa de pré-processamento, pois as informações sobre os gêneros de jogos e música favoritos podem contribuir para a análise das preferências dos indivíduos. A ausência desses atributos pode reduzir as informações disponíveis para os modelos. O tratamento dos valores ausentes será apresentado posteriormente, considerando a natureza categórica das variáveis e seu impacto nas tarefas de classificação e regressão.

2.4 Detecção de *Outliers*

A identificação de possíveis valores extremos foi realizada inicialmente por meio de uma análise visual utilizando boxplots das variáveis numéricas, com exceção de `person_id`, por se tratar de um identificador. Essa abordagem permitiu observar a distribuição dos dados e identificar variáveis que apresentavam observações potencialmente afastadas da região central da distribuição.

A partir da análise dos boxplots, foram identificados indícios de possíveis *outliers* nas variáveis `mood_score` e `social_media_hours_per_day`, apresentadas nas Figuras 2 e 3. As demais variáveis numéricas não apresentaram indícios visuais relevantes de valores extremos nos boxplots analisados.




Figura 2: Boxplot da variável `mood_score`.

A análise visual indicou comportamentos distintos entre as duas variáveis. Em `mood_score`,




Figura 3: Boxplot da variável social_media_hours_per_day.

observa-se a presença de valores no limite inferior da escala, enquanto a maior parte das observações está concentrada em valores mais elevados. Já em `social_media_hours_per_day`, observa-se uma quantidade maior de valores acima da região central da distribuição, com diversas observações chegando a 12 horas por dia. Esses valores representam observações extremas em relação à maior parte dos registros e foram investigados posteriormente por meio dos métodos estatísticos de detecção de *outliers*.

Para complementar a análise visual, foram aplicados os métodos do Intervalo Interquartil (IQR) e do Z-score. O método IQR baseia-se na diferença entre o terceiro quartil ($Q3$) e o primeiro quartil ($Q1$), sendo definido como $IQR = Q3 - Q1$. Foram considerados como possíveis *outliers* os valores localizados fora dos limites definidos por $Q1 - 1,5 \times IQR$ e $Q3 + 1,5 \times IQR$.

Para a variável `mood_score`, foram obtidos $Q1 = 4,9$ e $Q3 = 7,5$, resultando em um IQR de 2,6. Os limites inferior e superior calculados foram, respectivamente, 1,0 e 11,4. A aplicação do método identificou 32 observações como possíveis *outliers*.

Para a variável `social_media_hours_per_day`, foram obtidos $Q1 = 1,2$ e $Q3 = 3,5$, resultando em um IQR de 2,3. Os limites inferior e superior foram, respectivamente, -2,25 e 6,95, resultando em 189 observações classificadas como possíveis *outliers* pelo método.

O segundo método utilizado foi o Z-score, que considera a distância de cada observação em relação à média em unidades de desvio padrão. Neste estudo, foram considerados como possíveis *outliers* os valores com Z-score absoluto superior a 3.

Para `mood_score`, o método Z-score não identificou nenhuma observação como possível *outlier*. Já para `social_media_hours_per_day`, foram identificadas 83 observações. A Tabela 3 apresenta a comparação dos resultados obtidos pelos dois métodos.

Tabela 3: Comparação dos métodos de detecção de *outliers*

Variável	Método	Outliers
<code>mood_score</code>	IQR	32
<code>mood_score</code>	Z-score	0
<code>social_media_hours_per_day</code>	IQR	189
<code>social_media_hours_per_day</code>	Z-score	83

Os resultados evidenciam diferenças na quantidade de possíveis *outliers* identificados pelos dois métodos. Essa diferença ocorre porque os critérios utilizados são distintos. O IQR é baseado nos quartis e na dispersão dos 50% centrais dos dados, enquanto o Z-score considera a distância das observações em relação à média em unidades de desvio padrão.

No caso de `mood_score`, embora o método IQR tenha identificado 32 observações, a variável possui valores válidos entre 1 e 10. Dessa forma, a identificação estatística dessas observações como possíveis *outliers* não significa que elas representem erros nos dados. Para `social_media_hours_per_day`, também foram observados valores elevados, chegando a 12 horas por dia, que podem representar observações extremas, mas não necessariamente inválidas.

Os resultados obtidos pelos métodos estatísticos indicaram possíveis valores extremos nas variáveis analisadas. Esses resultados foram considerados na etapa de limpeza e pré-processamento, na qual foi avaliada a necessidade de remoção ou transformação dessas observações.

2.5 Correlação entre as variáveis numéricas

Para analisar a relação entre as variáveis numéricas, foram utilizadas as correlações de *Pearson* e *Spearman*. A correlação de Pearson permite avaliar relações lineares entre as variáveis, enquanto a correlação de Spearman avalia relações monotônicas e apresenta menor sensibilidade à influência de valores extremos.

A Figura 4 apresenta a matriz de correlação de Spearman das variáveis numéricas analisadas. Os coeficientes apresentaram valores muito próximos de zero, indicando que não foram identificadas relações monotônicas fortes entre as variáveis.

Entre os maiores valores absolutos observados, destacam-se as correlações entre *fear_tolerance* e *romance_interest* (0,03), entre *humor_preference* e *romance_interest* (0,03) e entre *risk_tolerance* e *romance_interest* (-0,03). Mesmo nesses casos, a intensidade da associação é muito baixa.

A matriz de Pearson apresentou resultados semelhantes aos observados por Spearman, também com coeficientes próximos de zero. Dessa forma, não foram identificadas evidências de relações lineares ou monotônicas fortes entre as variáveis numéricas analisadas.

Além disso, as correlações observadas não indicam a presença de multicolinearidade forte entre as variáveis preditoras. Entretanto, essa análise considera apenas as correlações entre pares de variáveis e, portanto, não substitui métodos específicos de avaliação de multicolinearidade, caso sejam necessários posteriormente na etapa de modelagem.



Figura 4: Matriz de correlação de Spearman das variáveis numéricas.

2.6 Distribuição das variáveis numéricas

Para complementar a análise exploratória, foram calculadas as medidas de assimetria e curtose das variáveis numéricas. A assimetria permite avaliar o grau de deslocamento da distribuição em relação à simetria, enquanto a curtose fornece informações sobre o comportamento das caudas da distribuição. Os resultados são apresentados na Tabela 4.

Os resultados indicam que a maioria das variáveis apresenta valores de assimetria próximos de zero, sugerindo distribuições aproximadamente simétricas. A variável `social_media_hours_per_day` apresenta o maior valor de assimetria, igual a 1,37, indicando um comportamento mais assimétrico em relação às demais variáveis.

Em relação à curtose, a maioria das variáveis apresentou valores negativos, enquanto `social_media_hours_per_day` apresentou valor positivo de 2,54. Esse resultado indica que essa variável apresenta comportamento distinto das demais em relação às caudas de sua distribuição.

A Figura 5 apresenta visualmente os valores de assimetria das variáveis numéricas. Observa-se que a maioria das variáveis apresenta valores próximos de zero. A princi-

Tabela 4: Assimetria e curtose das variáveis numéricas

Variável	Assimetria	Curtose
mood_score	-0,12	-0,33
stress_level	0,10	-0,49
fear_tolerance	0,14	-0,70
risk_tolerance	0,09	-0,58
humor_preference	-0,07	-0,52
openness_score	0,02	-0,54
romance_interest	0,09	-0,64
social_media_hours_per_day	1,37	2,54
streaming_subscription_count	0,09	-0,62

pal exceção é `social_media_hours_per_day`, que apresenta assimetria positiva de 1,37, destacando-se das demais variáveis. As variáveis `mood_score` e `humor_preference` apresentam assimetria negativa, com valores de $-0,12$ e $-0,07$, respectivamente, enquanto as demais apresentam assimetria positiva próxima de zero.




Figura 5: Assimetria das variáveis numéricas.

2.7 Distribuição das variáveis categóricas

A distribuição das variáveis categóricas foi analisada por meio de frequências e gráficos de barras, com o objetivo de identificar a representatividade das diferentes categorias presentes no conjunto de dados. Foram selecionadas algumas variáveis para representação gráfica, considerando sua relevância para a compreensão do conjunto e para as etapas posteriores de análise.

A Figura 6 apresenta a distribuição das faixas etárias. Observa-se uma maior concentração de registros nas categorias Adult (26-40) e Young Adult (18-25), enquanto a categoria Senior (60+) apresenta a menor quantidade de registros. Essa distribuição

evidencia diferenças na representatividade dos grupos etários presentes no conjunto de dados.




Figura 6: Distribuição das faixas etárias.

A Figura 7 apresenta a distribuição do gênero de jogo favorito. As categorias Action, RPG e Puzzle apresentam as maiores frequências, enquanto Racing apresenta menor frequência entre as categorias informadas. Também foram identificados 360 valores ausentes nessa variável, correspondentes a 6,00% dos registros, conforme observado anteriormente na análise de valores ausentes.

A Figura 8 apresenta a distribuição da variável `recommended_movie_genre`, que posteriormente será utilizada como variável-alvo no problema de classificação. A variável possui nove categorias, com maiores frequências para Action, Thriller e Drama, que apresentam aproximadamente 1.000 registros cada. Em contrapartida, Horror, Sci-Fi e Animation apresentam as menores frequências. Essa diferença na quantidade de registros entre as classes caracteriza uma distribuição desigual, que deverá ser considerada posteriormente na avaliação dos modelos de classificação.




Figura 7: Distribuição do gênero de jogo favorito.




Figura 8: Distribuição do gênero de filme recomendado.

3 Limpeza e Pré-processamento

3.1 Tratamento de Valores Ausentes

Foram identificados valores ausentes apenas nas variáveis `favorite_game_genre` e `favorite_music_genre`, correspondendo a 6,00% e 5,93% dos registros, respectivamente. Esses valores foram substituídos pela categoria `Nao_Informado`, evitando a perda de observações e representando explicitamente a ausência da informação.

Após o tratamento, foram mantidos os 6.000 registros do conjunto de dados.

3.2 Tratamento de *Outliers*

Os possíveis *outliers* foram analisados por meio dos métodos IQR e Z-score, considerando também a análise visual dos dados.

Foram identificados valores extremos em algumas variáveis, porém não foram encontradas evidências de erros de registro. Assim, optou-se pela manutenção dessas observações, evitando a remoção de dados potencialmente válidos.

3.3 Codificação das Variáveis Categóricas

As variáveis categóricas foram codificadas de acordo com suas características. Para variáveis com ordem natural, foi utilizado o Ordinal Encoding. Para variáveis nominais, foi utilizado o One-Hot Encoding.

A variável `hobbies` recebeu Multi-Hot Encoding, pois um mesmo registro pode possuir mais de um hobby. Já a variável `recommended_movie_genre`, utilizada como alvo na classificação, foi codificada por meio do Label Encoding.

As variáveis originais foram mantidas no conjunto de dados, enquanto as representações codificadas foram adicionadas como novas colunas.

3.4 Padronização das Variáveis Numéricas

A padronização das variáveis numéricas será realizada durante a etapa de modelagem utilizando a técnica de Z-score, por meio do `StandardScaler`. Essa transformação tem como objetivo colocar as variáveis em uma escala comparável, reduzindo a influência das diferenças de escala nos algoritmos sensíveis a esse fator.

Como serão avaliados diferentes modelos, a padronização será realizada após a divisão dos dados em conjuntos de treinamento e teste. O ajuste (*fit*) do método será realizado exclusivamente com os dados de treinamento, enquanto a transformação (*transform*) será aplicada tanto aos dados de treinamento quanto aos dados de teste utilizando os parâmetros obtidos no treinamento.

Essa abordagem evita o vazamento de informações do conjunto de teste para o treinamento e permite realizar uma avaliação mais adequada do desempenho dos modelos.

4 Percepções para Classificação

4.1 Seleção da Variável-Alvo

Para a classificação, foi selecionada a variável *recommended_movie_genre*, que representa o gênero de filme recomendado. A variável possui nove classes, com diferentes frequências de observações.

4.2 Features Recomendadas

A seleção das características foi realizada por meio do teste do Qui-Quadrado, V de Cramér, teste de Kruskal-Wallis, SelectKBest, RFE e importância das variáveis pelo Random Forest.

De forma geral, os resultados indicaram maior relevância para *openness_score*, *risk_tolerance*, *stress_level*, *romance_interest*, *humor_preference*, *fear_tolerance*, *age_group* e *favorite_game_genre*. Essas variáveis são recomendadas como principais candidatas para o modelo de classificação.

4.3 Desafios

O principal desafio é a existência de nove classes com diferentes frequências. Também é possível que algumas classes apresentem maior dificuldade de classificação. Por isso, recomenda-se utilizar divisão estratificada dos dados e métricas como *precision*, *recall* e *F₁-Score Macro*.

4.4 Algoritmos Sugeridos

Como modelos iniciais, podem ser testados a Regressão Logística, como *baseline*, e o Random Forest Classifier, por sua capacidade de representar relações não lineares e interações entre as características.

5 Percepções para Regressão

5.1 Seleção da Variável-Alvo

Para a regressão, foi selecionada a variável *social_media_hours_per_day*, por apresentar natureza quantitativa e maior quantidade de valores distintos entre as variáveis

numéricas.

5.2 Features Recomendadas

A relação com a variável-alvo foi analisada por meio das correlações de Pearson e Spearman, SelectKBest, teste de Kruskal-Wallis e importância das variáveis pelo Random Forest.

Os resultados indicaram relações muito fracas entre as variáveis numéricas e o alvo. O SelectKBest destacou as variáveis *mood_score*, *fear_tolerance*, *risk_tolerance*, *romance_interest* e *streaming_subscription_count*. Essas variáveis foram utilizadas inicialmente como candidatas para a modelagem da regressão.

Por outro lado, o Random Forest apresentou maior importância relativa para *openness_score*, *humor_preference*, *risk_tolerance*, *mood_score*, *stress_level*, *fear_tolerance* e *romance_interest*. Entre as variáveis categóricas, *personality_type* apresentou associação estatisticamente significativa com o alvo pelo teste de Kruskal-Wallis, embora o efeito observado tenha sido pequeno.

Dessa forma, as variáveis analisadas são consideradas candidatas para a regressão, mas os resultados não indicam forte poder preditivo individual. A seleção definitiva das features deve considerar também o desempenho dos modelos.

5.3 Desafios

O principal desafio identificado foi a baixa relação entre as variáveis disponíveis e o alvo de regressão. As correlações entre as variáveis numéricas apresentaram valores próximos de zero, enquanto a análise das variáveis categóricas indicou apenas uma associação estatisticamente significativa, com efeito pequeno.

Na modelagem inicial, utilizando as cinco variáveis selecionadas pelo SelectKBest, a Regressão Linear apresentou MAE de 1,359, RMSE de 1,776 e R^2 de 0,0004. O Random Forest Regressor apresentou MAE de 1,431, RMSE de 1,836 e R^2 de -0,068.

Os resultados indicaram baixo poder preditivo para os dois modelos, reforçando a limitação do conjunto de dados para explicar a variação de *social_media_hours_per_day*.

5.4 Algoritmos Sugeridos

Foram avaliados inicialmente a Regressão Linear, utilizada como *baseline*, e o Random Forest Regressor, considerando a possibilidade de existência de relações não lineares. A Regressão Linear apresentou melhor desempenho nos resultados obtidos, com menores valores de MAE e RMSE e R^2 próximo de zero. O Random Forest apresentou R^2 negativo, indicando desempenho inferior ao da previsão baseada na média do alvo.

Apesar da diferença de desempenho, ambos os modelos apresentaram baixo poder preditivo, indicando que a escolha do algoritmo não foi suficiente para superar a limitação

das características disponíveis no conjunto de dados.

6 Considerações Finais

A realização deste trabalho permitiu aplicar, de forma prática, diferentes etapas de análise exploratória, limpeza e preparação de dados para problemas de Inteligência Artificial. A análise do conjunto de dados possibilitou identificar características das variáveis, tratar valores ausentes, avaliar possíveis *outliers* e investigar relações entre as variáveis para as tarefas de regressão e classificação.

Entre as principais dificuldades esteve a definição adequada das estratégias de tratamento, especialmente na identificação das características das variáveis categóricas e na análise de valores extremos. Na regressão, um dos principais aprendizados foi perceber que a ausência de relações fortes entre as variáveis e o alvo pode limitar significativamente o desempenho dos modelos. Os experimentos realizados mostraram baixo poder preditivo, reforçando a importância de analisar os dados antes de escolher as características e os algoritmos.

De forma geral, o trabalho reforçou a importância da qualidade e da preparação dos dados para o desenvolvimento de modelos de Inteligência Artificial. Também foi possível compreender que os resultados dos modelos devem ser analisados criticamente, pois nem sempre a aplicação de algoritmos é suficiente para obter boas previsões quando as informações disponíveis não apresentam relações relevantes com o problema estudado.